《Multirate Factor Analysis Models for Fault Detection in Multirate Processes》方法报告

2026-03-27

目录

1 文档目标 **2**

2 方法总览 **2**

2.1 一句话概括 2

2.2 论文试图解决的问题 2

3 从 FA 到 MR-FA **3**

3.1 单速率 FA 回顾 3

3.2 MR-FA 的关键变化 3

4 符号与张量形状 **3**

4.1 论文原始表示 3

4.2 核心符号表 4

4.3 工程实现视角下的张量化表示 4

5 模型输入、输出与中间结果 **5**

5.1 训练输入 5

5.2 训练输出 5

5.3 测试时输出 5

6 MR-FA 的数学结构 **5**

6.1 生成模型 5

6.2 采样指示器的作用 6

6.3 后验推断 6

7 张量形状分析 **7**

7.1 单时间步上的形状传播 7

7.2 M 步中的形状传播 7

7.3 批量实现时最常见的张量 7

8 训练数据流：从输入到参数更新 **8**
8.1 总流程 8
8.2 E 步：估计隐因子后验 8
8.3 M 步：更新载荷和噪声 8
8.4 为什么这能建模跨采样率相关性 9

9 推理与故障检测数据流 **9**
9.1 测试时的因子推断 9
9.2 公共子空间统计量 T^2 9
9.3 残差统计量 SPE 9
9.4 控制限 10

10 几何解释 **10**
10.1 单个 FA 的几何意义 10
10.2 MR-FA 的几何意义 10

11 与其他方法的差异 **10**
11.1 与下采样/上采样方法的差异 10
11.2 与多个独立 FA 的差异 10
11.3 与 MRPCA 的差异 11

12 方法的优点、假设与局限 **11**
12.1 优点 11
12.2 核心假设 11
12.3 局限 11

13 面向实现的数据流总结 **11**
13.1 训练期 11
13.2 推理期 12
13.3 如果一定要写成“输入张量 → 输出张量” 12

14 论文实验结论简述 **12**

15 结论 **13**

1 文档目标

本文围绕 Zhou 等人在 2019 年提出的 MR-FA（Multirate Factor Analysis，多采样率因子分析）方法，给出一份面向工程实现的中文技术报告。报告重点回答四个问题：

- 论文到底提出了什么模型；
- 这个模型的输入、输出和中间量分别是什么，形状如何；
- 训练和推理时的数据流是怎样流动的；
- 相关数学原理应该如何理解，尤其是共享潜因子、EM 训练和故障检测统计量。

需要先说明一点：这篇论文本身不是深度学习论文，原文使用的是矩阵和向量记号，而不是神经网络里常见的“张量层”。因此，本文会在**保留论文原意**的基础上，把它**改写成工程上更容易实现的张量视角**。

2 方法总览

2.1 一句话概括

MR-FA 的核心思想是：**把不同采样率的变量都看成由同一组潜在公共因子驱动**，只是不同采样率在不同时间点上是否观测到、每组变量的维数、噪声强度都不一样。模型通过共享潜因子把“同采样率内部相关性”和“不同采样率之间的相关性”统一起来，而不是先上采样/下采样再做普通 FA。

2.2 论文试图解决的问题

工业过程里常见三类变量：

- 高频在线传感器变量；
- 中频过程变量；
- 低频实验室质量变量。

传统 MSPM 方法大多默认所有变量同频采样。常见补救方法是：

- 下采样到最慢频率；
- 上采样并插补慢变量；
- 只用高频变量，忽略低频质量变量。

这些做法都会损失信息或者扭曲真实相关结构。MR-FA 的目标就是直接在多采样率观测上建模，而不强行把数据压成单一频率。

3 从 FA 到 MR-FA

3.1 单速率 FA 回顾

普通因子分析（FA）假设观测向量 $\boldsymbol{x} \in \mathbb{R}^M$ 来自一个低维潜变量 $\boldsymbol{t} \in \mathbb{R}^D$：

$$\boldsymbol{x} = \boldsymbol{\Psi}\boldsymbol{t} + \boldsymbol{\varepsilon}, \tag{1}$$

其中：

- $\boldsymbol{\Psi} \in \mathbb{R}^{M \times D}$ 是因子载荷矩阵；
- $\boldsymbol{t} \sim \mathcal{N}(\boldsymbol{0}, \boldsymbol{I})$；
- $\boldsymbol{\varepsilon} \sim \mathcal{N}(\boldsymbol{0}, \boldsymbol{\Omega})$；
- $\boldsymbol{\Omega}$ 是对角阵，而不是 PPCA 中的 $\sigma^2 \boldsymbol{I}$。

这意味着 FA 允许每个变量拥有不同噪声方差，因此比 PPCA 的各向同性噪声假设更灵活。

3.2 MR-FA 的关键变化

对多采样率情形，论文把单个 FA 扩展为 N 个采样率组：

$$\boldsymbol{x}_n(k) = \boldsymbol{\Psi}_n \boldsymbol{t}(k) + \boldsymbol{\xi}_n(k), \quad n = 1, 2, \ldots, N. \tag{2}$$

这里最关键的不是“有 N 个方程”，而是**所有采样率组共享同一个时刻的潜因子 $\boldsymbol{t}(k)$**。也就是说：

- 第 n 组变量有自己的载荷矩阵 $\boldsymbol{\Psi}_n$；
- 第 n 组变量有自己的对角噪声协方差 $\boldsymbol{\Omega}_n$；
- 但它们在同一个全局时间索引 k 上由同一潜状态 $\boldsymbol{t}(k)$ 驱动。

这使得跨采样率相关性不需要显式写成交叉协方差块，而是通过共享潜因子自然耦合起来。

4 符号与张量形状

4.1 论文原始表示

设整个系统包含 N 个采样率组，第 n 组数据矩阵为

$$\boldsymbol{X}_n \in \mathbb{R}^{K_n \times M_n}, \tag{3}$$

其中：

- K_n 是第 n 个采样率组实际采到的样本数；
- M_n 是第 n 个采样率组包含的变量个数。

论文再引入一个**全局时间轴**，长度记为 K，满足

$$K \geq \max(K_1, \ldots, K_N), \tag{4}$$

并且每个全局时间点 k 至少有一组变量被采到。

4.2 核心符号表

符号	形状	含义
N	标量	采样率组个数
M_n	标量	第 n 组变量维度
K_n	标量	第 n 组实际采样次数
K	标量	统一后的全局时间步数
D	标量	公共潜因子维度
$\boldsymbol{x}_n(k)$	$\mathbb{R}^{M_n}$	第 n 组在全局时刻 k 的观测向量
$\boldsymbol{X}_n$	$\mathbb{R}^{K_n \times M_n}$	第 n 组完整训练数据矩阵
$\phi_{k,n}$	$\{0,1\}$	采样指示器，表示时刻 k 是否观测到第 n 组
$\boldsymbol{X}_o(k)$	$\mathbb{R}^{m_k}$	时刻 k 所有已观测组拼接后的向量，$m_k = \sum_n \phi_{k,n} M_n$
$\boldsymbol{t}(k)$	$\mathbb{R}^D$	时刻 k 的公共潜因子
$\hat{\boldsymbol{t}}(k)$	$\mathbb{R}^D$	潜因子后验均值
$\boldsymbol{\Psi}_n$	$\mathbb{R}^{M_n \times D}$	第 n 组载荷矩阵
$\boldsymbol{\Omega}_n$	$\mathbb{R}^{M_n \times M_n}$	第 n 组噪声协方差，对角阵
$\boldsymbol{\Sigma}(k)$	$\mathbb{R}^{D \times D}$	论文符号中的后验精度矩阵
$\mathbb{E}[\boldsymbol{t}(k)\boldsymbol{t}(k)^\top \mid \boldsymbol{X}_o(k)]$	$\mathbb{R}^{D \times D}$	后验二阶矩
$T^2(k)$	标量	公共因子子空间监控统计量
$\mathrm{SPE}_n(k)$	标量	第 n 组残差平方统计量

4.3 工程实现视角下的张量化表示

论文的原始输入并不是单个规整的三维张量，因为不同采样率组的维数 M_n 往往不同。因此最自然的实现方式其实是：

$$\{\boldsymbol{X}_1, \boldsymbol{X}_2, \ldots, \boldsymbol{X}_N\}, \tag{5}$$

也就是一个“矩阵列表”。

如果为了向量化实现，也可以构造填充后的张量：

$$\mathcal{X}_{\mathrm{pad}} \in \mathbb{R}^{K \times N \times M_{\max}}, \quad M_{\max} = \max_n M_n, \tag{6}$$

并配套使用掩码：

$$\mathcal{M}_{\mathrm{pad}} \in \{0,1\}^{K \times N \times M_{\max}}, \tag{7}$$

以及组级采样指示器：

$$\boldsymbol{\Phi} \in \{0,1\}^{K \times N}. \tag{8}$$

结论 从论文角度看，**输入不是一个标准 dense tensor，而是多组不同形状矩阵加一个全局时间对齐机制**；从工程角度看，可以把它实现成“填充张量 + 掩码”或“按组存储 + 观测模式分桶”。

5 模型输入、输出与中间结果

5.1 训练输入

训练集由正常工况数据组成，输入包括：

- 多采样率观测集合 $\{\boldsymbol{X}_n\}_{n=1}^N$；
- 全局时间轴上的采样指示器 $\phi_{k,n}$。

如果按统一时间轴表示，则单个时间步的输入是：

$$\{\boldsymbol{x}_n(k), \phi_{k,n}\}_{n=1}^N. \tag{9}$$

真正参与当前步推断的观测是拼接向量 $\boldsymbol{X}_o(k)$。

5.2 训练输出

训练结束后得到的不是类别标签，而是一个生成式监测模型：

- 各组载荷矩阵 $\{\boldsymbol{\Psi}_n\}_{n=1}^N$；
- 各组噪声协方差 $\{\boldsymbol{\Omega}_n\}_{n=1}^N$；
- 训练数据上各时刻的后验因子均值 $\hat{\boldsymbol{t}}(k)$；
- 每个时刻的 T^2 统计量和每个采样率组对应的 SPE_n 统计量；
- 基于训练分布估计出的控制限。

5.3 测试时输出

对新时刻 k_{new} 的观测，模型输出：

- 因子估计 $\hat{\boldsymbol{t}}(k_{\text{new}}) \in \mathbb{R}^D$；
- 公共子空间统计量 $T^2(k_{\text{new}})$；
- 每个采样率组的残差统计量 $\mathrm{SPE}_n(k_{\text{new}})$。

如果批量处理 K_{test} 个测试时刻，那么：

$$\hat{\boldsymbol{T}} \in \mathbb{R}^{K_{\text{test}} \times D}, \quad \boldsymbol{t}^2 \in \mathbb{R}^{K_{\text{test}}}, \quad \mathrm{SPE} \in \mathbb{R}^{K_{\text{test}} \times N}. \tag{10}$$

6 MR-FA 的数学结构

6.1 生成模型

MR-FA 在每个时间步上是一个线性高斯潜变量模型。对第 n 个采样率组：

$$\boldsymbol{x}_n(k) = \boldsymbol{\Psi}_n \boldsymbol{t}(k) + \boldsymbol{\xi}_n(k), \tag{11}$$

其中

$$\boldsymbol{t}(k) \sim \mathcal{N}(\mathbf{0}, \boldsymbol{I}), \tag{12}$$

$$\boldsymbol{\xi}_n(k) \sim \mathcal{N}(\mathbf{0}, \boldsymbol{\Omega}_n), \tag{13}$$

$$\boldsymbol{\Omega}_n = \mathrm{diag}(\omega_{n,1}, \ldots, \omega_{n,M_n}). \tag{14}$$

这意味着：

- 潜因子之间先验不相关；
- 同组变量的噪声在论文里被假设为相互独立；
- 不同组之间的统计耦合不是通过噪声项给出，而是通过共享潜因子给出。

6.2 采样指示器的作用

由于某些组在时刻 k 没有采到，所以后验推断不能直接把所有组硬拼起来。论文用

$$\phi_{k,n} = \begin{cases} 1, & \text{时刻}k \text{ 观测到第}n \text{ 组}, \\ 0, & \text{否则} \end{cases} \tag{15}$$

来决定当前时刻有哪些组参与推断。

因此，MR-FA 是一个**结构随时间变化的模型**：时刻 k 真正生效的并不是全部参数块，而是所有满足 $\phi_{k,n} = 1$ 的那部分参数块。这也是论文把 MR-FA 视为一种特殊时变模型的原因。

6.3 后验推断

固定当前参数 $\{\boldsymbol{\Psi}_n, \boldsymbol{\Omega}_n\}$ 时，时刻 k 的潜因子后验均值为：

$$\hat{\boldsymbol{t}}(k) = \boldsymbol{\Sigma}(k)^{-1} \sum_{n=1}^{N} \phi_{k,n} \boldsymbol{\Psi}_n^\top \boldsymbol{\Omega}_n^{-1} \boldsymbol{x}_n(k). \tag{16}$$

其中

$$\boldsymbol{\Sigma}(k) = \sum_{n=1}^{N} \phi_{k,n} \boldsymbol{\Psi}_n^\top \boldsymbol{\Omega}_n^{-1} \boldsymbol{\Psi}_n + \boldsymbol{I}. \tag{17}$$

后验二阶矩为：

$$\mathbb{E}\big[\boldsymbol{t}(k)\boldsymbol{t}(k)^\top \mid \boldsymbol{X}_o(k)\big] = \boldsymbol{\Sigma}(k)^{-1} + \hat{\boldsymbol{t}}(k)\hat{\boldsymbol{t}}(k)^\top. \tag{18}$$

一个容易混淆但很重要的点 论文把 $\boldsymbol{\Sigma}(k)$ 记成了一个类似“协方差”的符号，但从公式结构看，它实际上是**后验精度矩阵**，因为真正的后验协方差是 $\boldsymbol{\Sigma}(k)^{-1}$。这一点在阅读公式和做代码实现时必须分清。

7 张量形状分析

7.1 单时间步上的形状传播

对某个时刻 k，第 n 组的关键量形状如下：

$$\boldsymbol{x}_n(k) : M_n \times 1, \tag{19}$$

$$\boldsymbol{\Psi}_n : M_n \times D, \tag{20}$$

$$\boldsymbol{\Omega}_n^{-1} : M_n \times M_n, \tag{21}$$

$$\boldsymbol{\Psi}_n^\top \boldsymbol{\Omega}_n^{-1} \boldsymbol{x}_n(k) : D \times 1. \tag{22}$$

于是多组贡献求和后得到：

$$\sum_{n=1}^{N} \phi_{k,n} \boldsymbol{\Psi}_n^\top \boldsymbol{\Omega}_n^{-1} \boldsymbol{x}_n(k) \in \mathbb{R}^D. \tag{23}$$

再乘上 $\boldsymbol{\Sigma}(k)^{-1} \in \mathbb{R}^{D\times D}$，得到

$$\hat{\boldsymbol{t}}(k) \in \mathbb{R}^D. \tag{24}$$

7.2 M 步中的形状传播

固定第 n 组，更新载荷矩阵时：

$$\hat{\boldsymbol{\Psi}}_n = \left(\sum_{k=1}^{K} \phi_{k,n} \boldsymbol{x}_n(k) \hat{\boldsymbol{t}}(k)^\top \right) \left(\sum_{k=1}^{K} \phi_{k,n} \mathbb{E}\big[\boldsymbol{t}(k) \boldsymbol{t}(k)^\top \mid \boldsymbol{X}_o(k) \big] \right)^{-1}. \tag{25}$$

其中：

- $\boldsymbol{x}_n(k)\hat{\boldsymbol{t}}(k)^\top$ 的形状是 $M_n \times D$；
- 分母是 $D \times D$；
- 所以最终 $\hat{\boldsymbol{\Psi}}_n$ 形状仍是 $M_n \times D$。

噪声协方差更新为：

$$\hat{\boldsymbol{\Omega}}_n = \operatorname{diag}\left(\boldsymbol{S}_n - \frac{1}{K_n} \sum_{k=1}^{K} \phi_{k,n} \hat{\boldsymbol{\Psi}}_n \hat{\boldsymbol{t}}(k) \boldsymbol{x}_n(k)^\top \right), \tag{26}$$

其中

$$\boldsymbol{S}_n = \frac{1}{K_n} \sum_{k=1}^{K_n} \boldsymbol{x}_n(k) \boldsymbol{x}_n(k)^\top \in \mathbb{R}^{M_n \times M_n}. \tag{27}$$

7.3 批量实现时最常见的张量

若按工程代码批量实现，一般会出现下列张量：

- 观测模式矩阵 $\boldsymbol{\Phi} \in \{0,1\}^{K\times N}$；
- 后验均值矩阵 $\hat{\boldsymbol{T}} \in \mathbb{R}^{K\times D}$；
- 后验精度张量 $\mathcal{P} \in \mathbb{R}^{K\times D\times D}$；
- 后验协方差张量 $\mathcal{C} \in \mathbb{R}^{K\times D\times D}$；

- 二阶矩张量 $\mathcal{S} \in \mathbb{R}^{K\times D\times D}$；
- 监测统计量 $\boldsymbol{t}^2 \in \mathbb{R}^K$；
- 残差统计量矩阵 $\mathrm{SPE} \in \mathbb{R}^{K\times N}$。

对应到仓库实现 仓库中的 `baseline/mr_fa.py` 基本就是这个张量化思路：

- `phi`: (K, N)；
- `means`: (K, D)；
- `precisions`: (K, D, D)；
- `covariances`: (K, D, D)；
- `second_moments`: (K, D, D)；
- `spe`: (K, N)。

8 训练数据流：从输入到参数更新

8.1 总流程

MR-FA 的训练可以写成下面的数据流：

$$\{\boldsymbol{X}_n\}_{n=1}^N \longrightarrow \{\boldsymbol{X}_o(k), \phi_{k,:}\}_{k=1}^K \xrightarrow{\text{E-step}} \{\hat{\boldsymbol{t}}(k), \mathbb{E}[\boldsymbol{t}(k)\boldsymbol{t}(k)^\top]\}_{k=1}^K \xrightarrow{\text{M-step}} \{\boldsymbol{\Psi}_n, \boldsymbol{\Omega}_n\}_{n=1}^N. \tag{28}$$

训练只使用正常工况数据，因此本质上是一个无监督建模过程。

8.2 E 步：估计隐因子后验

在 E 步，参数固定，逐时刻推断公共因子。可以把它理解为：

1. 先看当前时刻有哪些组被观测到；
2. 把这些组各自对潜因子的“证据”映射到 D 维潜空间；
3. 把所有证据相加；
4. 再乘以后验协方差，得到当前时刻的最佳因子估计。

由于模型是线性高斯的，上述结果是标准高斯共轭推断的闭式解。

8.3 M 步：更新载荷和噪声

在 M 步，潜因子后验矩固定，用最大似然更新参数：

- $\boldsymbol{\Psi}_n$ 由“观测与潜因子”的交叉矩估计；
- $\boldsymbol{\Omega}_n$ 由该组的残差协方差对角部分估计。

注意这里虽然更新是按组进行的，但**每个组的更新并不是只用本组数据**。原因在于：

- $\hat{\boldsymbol{t}}(k)$ 是由当前时刻**所有已观测组**共同决定的；
- 所以一旦第 n 组在时刻 k 出现，它的参数更新就间接受到了其他组观测的影响。

这正是论文强调的“MR-FA 不等价于多个独立 FA”的根本原因。

8.4 为什么这能建模跨采样率相关性

如果为每个采样率单独训练一个 FA：

- 每组只看到自己；
- 每组有自己的潜因子；
- 组间没有共享隐状态，因此无法利用跨组共现信息。

MR-FA 则相反：

- 各组有各自的观测头 $\boldsymbol{\Psi}_n$；
- 但共享同一潜空间 $\boldsymbol{t}(k)$；
- 只要多个采样率在某些时间点共现，它们就会通过同一个 $\boldsymbol{t}(k)$ 彼此约束。

9 推理与故障检测数据流

9.1 测试时的因子推断

对新时刻 k_{new} 的观测，仍然使用与训练 E 步相同的后验推断公式：

$$\hat{\boldsymbol{t}}(k_{\text{new}}) = \boldsymbol{\Sigma}(k_{\text{new}})^{-1} \sum_{n=1}^{N} \phi_{k_{\text{new}},n} \boldsymbol{\Psi}_n^\top \boldsymbol{\Omega}_n^{-1} \boldsymbol{x}_n(k_{\text{new}}). \tag{29}$$

9.2 公共子空间统计量 T^2

论文定义：

$$T^2(k_{\text{new}}) = \hat{\boldsymbol{t}}(k_{\text{new}})^\top \boldsymbol{\Sigma}(k_{\text{new}})^{-1} \hat{\boldsymbol{t}}(k_{\text{new}}). \tag{30}$$

直观上，T^2 衡量的是“当前样本在公共潜空间中偏离正常模式的程度”。如果一个故障会显著改变多个采样率共享的潜在机理，那么它往往会首先在 T^2 上表现出来。

9.3 残差统计量 SPE

对每个采样率组，先做重构：

$$\hat{\boldsymbol{x}}_n(k) = \boldsymbol{\Psi}_n \hat{\boldsymbol{t}}(k), \tag{31}$$

再计算残差：

$$\boldsymbol{e}_n(k) = \boldsymbol{x}_n(k) - \hat{\boldsymbol{x}}_n(k), \tag{32}$$

最后得到

$$\text{SPE}_n(k) = \boldsymbol{e}_n(k)^\top \boldsymbol{e}_n(k). \tag{33}$$

SPE_n 反映的是“第 n 组变量中无法被共享潜因子解释的那部分能量”。因此：

- T^2 更偏向监控共享子空间；
- SPE_n 更偏向监控各组残差子空间。

9.4 控制限

论文采用：

- T^2 的控制限由 F 分布估计；
- SPE_n 的控制限由卡方分布估计。

因此完整检测流程可以写成：

$$\text{新观测} \to \hat{\boldsymbol{t}} \to \left(T^2, \mathrm{SPE}_1, \ldots, \mathrm{SPE}_N\right) \to \text{与控制限比较} \to \text{报警/不报警}. \tag{34}$$

10 几何解释

10.1 单个 FA 的几何意义

单个 FA 可以理解为：在 M 维观测空间中寻找一个 D 维超平面，让样本投影到这个平面后，尽可能保留原始变量之间的相关结构。观测向量可以分解为：

$$\boldsymbol{x} = \hat{\boldsymbol{x}} + \boldsymbol{\xi}, \tag{35}$$

其中 $\hat{\boldsymbol{x}}$ 是投影部分，$\boldsymbol{\xi}$ 是残差。

10.2 MR-FA 的几何意义

MR-FA 不是分别给每个采样率找一个超平面，而是让**所有采样率组共享同一个潜在超平面**。因此它优化的不是某一组内部的局部误差最小，而是所有采样率组总体残差协方差的全局最小。

论文的几何解释可以概括为：

- 先只用一种采样率时，会得到一个超平面；
- 再加入另一种采样率后，最优超平面会旋转；
- 这个旋转的结果，是为了让所有采样率组在同一个共享潜空间上达到更好的整体拟合。

这个观点很重要，因为它解释了为什么 MR-FA 与“多个独立 FA 模型”在本质上不同。

11 与其他方法的差异

11.1 与下采样/上采样方法的差异

MR-FA 不先把所有变量压成同频数据，因此避免了两个问题：

- 下采样导致高频信息损失；
- 上采样导致人工插值破坏真实相关性。

11.2 与多个独立 FA 的差异

独立 FA 的问题是每组潜因子互不共享，因此：

- 不能显式学习跨采样率相关性；
- 低频质量变量无法反向约束高频过程变量的潜空间；
- 最终更像多个局部模型，而不是一个统一过程模型。

11.3 与 MRPCA 的差异

论文把 MR-FA 与之前的 MRPCA 进行了比较。最关键的差异是：

- MRPCA 仍然继承了 PPCA 风格的各向同性噪声假设；
- MR-FA 允许每个变量有自己的噪声方差，因此对工业数据更现实。

对工业过程数据而言，不同变量的噪声幅值差异通常很大，所以这一点确实重要。

12 方法的优点、假设与局限

12.1 优点

- 不需要先统一采样率；
- 共享潜因子，能同时利用组内和组间相关性；
- 比 MRPCA 更灵活，因为噪声方差不是各向同性；
- 输出既有潜空间统计量 T^2，也有分组残差统计量 SPE_n，监测解释性较好。

12.2 核心假设

- 线性生成关系：$\boldsymbol{x}_n = \boldsymbol{\Psi}_n \boldsymbol{t} + \boldsymbol{\xi}_n$；
- 潜因子服从标准高斯先验；
- 每组内部噪声协方差为对角阵；
- 不同采样率的耦合主要通过共享潜因子，而不是通过动态时序模型显式建模。

12.3 局限

- 这是静态线性模型，不直接建模时间动态；
- 如果不同采样率互为互素并且共现很少，跨组耦合会变弱；
- 对角噪声协方差仍然是一种简化，无法表示同组变量残差之间的相关噪声；
- EM 只能保证收敛到局部最优。

13 面向实现的数据流总结

13.1 训练期

用更接近代码的方式，训练流程可以概括为：

1. 读入各采样率组数据 $\{\boldsymbol{X}_n\}$；
2. 建立全局时间轴，并生成组级观测掩码 $\boldsymbol{\Phi}$；
3. 初始化 $\{\boldsymbol{\Psi}_n, \boldsymbol{\Omega}_n\}$；

4. 对每个观测模式重复执行 E 步，得到所有时刻的 $\hat{\boldsymbol{t}}(k)$ 和二阶矩；
5. 对每个采样率组执行 M 步，更新 $\boldsymbol{\Psi}_n, \boldsymbol{\Omega}_n$；
6. 重复 4–5 直到对数似然收敛；
7. 在训练集上计算 T^2 和 SPE_n 的控制限。

13.2 推理期

1. 输入新时刻的多采样率观测；
2. 根据当前观测模式计算 $\hat{\boldsymbol{t}}$；
3. 对每个已观测组做重构并求残差；
4. 输出 T^2 和各组 SPE_n；
5. 与控制限比较，给出报警结果。

13.3 如果一定要写成“输入张量 → 输出张量”

可以写成：

$$\mathcal{X}_{\mathrm{pad}} \in \mathbb{R}^{K \times N \times M_{\max}}, \tag{36}$$

$$\boldsymbol{\Phi} \in \{0,1\}^{K \times N}, \tag{37}$$

$$\hat{\boldsymbol{T}} \in \mathbb{R}^{K \times D}, \tag{38}$$

$$\mathcal{C} \in \mathbb{R}^{K \times D \times D}, \tag{39}$$

$$\mathrm{SPE} \in \mathbb{R}^{K \times N}. \tag{40}$$

但要强调：**这只是工程上的统一封装方式，不是论文最原生的数学表达**。论文原生表达更接近“多组矩阵 + 条件观测模式”。

14 论文实验结论简述

论文用两个案例验证方法：

- Tennessee–Eastman 模拟过程；
- 造纸废水处理中的 R2S 厌氧反应器真实数据。

整体结论是：

- MR-FA 普遍优于下采样 FA、只用高频变量的 FA，以及早期的 MRPCA；
- 尤其在需要依赖低频质量变量才能识别的故障上，MR-FA 的优势更明显；
- 论文将性能优势主要归因于两点：完整利用多采样率信息，以及更合理的异方差噪声建模。

15 结论

MR-FA 可以看成是**多采样率场景下的共享潜因子生成模型**。它的本质不是补齐缺失数据，也不是给每种采样率单独建模，而是在统一时间轴上用一个共享潜空间解释所有可见观测。对工程实现而言，最重要的理解有三点：

- 输入本质上是“多组不同形状矩阵 + 采样指示器”，不是天然规则的单张量；
- 模型的核心输出是各时刻公共因子后验、各组载荷矩阵与噪声方差，以及由此得到的 T^2/SPE 统计量；
- 整个数据流由“观测模式 → 后验因子 → 参数更新/残差统计”三段组成，其中跨采样率信息融合发生在共享潜因子的后验推断阶段。